分阶段优化与最终测试复核

2026 年 11 月 1 日 第二轮完整优化与固定候选评估

本轮完成 E1 至 E10 及针对性补充实验，共 28 个配置、108 次模型训练运行，累计 310 个训练 epoch。全部优化、三种子复验及最终一次测试均已结束，但固定候选仍差于 E0，本轮未实现可接受的测试集提分。

最终固定行情平均的留出 MAE 为 0.362524，MSE 为 0.335653；固定多模态平均为 0.362524 和 0.335653。下表同时保留基线及上一轮失败候选，所有指标均为标准化 Close 尺度，越低越好。

同一内部留出集	MAE	MSE
E0 最后值	0.354286	0.330340
历史增强 E1	0.351294	0.324072
历史 E6 三种子平均	0.350345	0.320201
历史优化 PatchTST	0.353688	0.328020
上一轮 B2 候选	0.362970	0.339169
本轮固定行情平均	0.362524	0.335653
本轮多模态实验配置	0.362524	0.335653

行情候选相对 E0 的 MAE 变化为+2.33%，MSE 变化为+1.61%；负数表示改善。

多模态候选相对 E0 的 MAE 变化为+2.33%，MSE 变化为+1.61%；负数表示改善。

本次测试共 15,390 条样本，预测起始日期为 2024 年 1 月 24 日至 2 月 27 日，目标最晚到 3 月 29 日。这是此前已揭晓的内部时间留出，官方隐藏测试集仍未公开；不能将本次结果描述为新的盲测。

1 验证方案和训练预算

上轮 B2 在开发集有收益，却在内部留出上退化。本轮将跨时段稳定性放到较低的单一开发分数之前，优化期间只使用训练和开发范围，最后两个候选的成员、种子与等权规则均在测试前冻结。

时间范围	训练样本	验证样本	边界规则
rolling_A	440221	29152	训练目标结束早于 2023 年 1 月 3 日；验证起始日为 1 月 3 日至 2 月 28 日。
rolling_B	535747	33210	训练目标结束早于 2023 年 7 月 3 日；验证起始日为 7 月 3 日至 8 月 31 日。
development	587587	42930	使用全部官方训练样本；验证使用原 42,930 条开发样本，保留原隔离边界。

优化与选轮规则

每配置 seed42 最多 8 轮、patience 为 2、batch 为 512。AdamW 学习率 0.0002、权重衰减 0.05。每个时间范围内再按预测起始日划三段，以最差一段的 MAE/E0 加 0.25 倍最差 MSE/E0 选检查点，保留 epoch0 最后值参照。三段目标可能重叠，因此只是压力检查。

跨三个时间范围比较匹配配置：平均 MAE 至少改善 0.1%，每个范围 MSE 不升，各段 MAE 不恶化超过 0.25%。合格行情还需通过相对 E0 的各段 MAE 与 MSE 上限。未通过的改动按原方案保留基线，不能因某一开发总分更低就采用。

限制预测修正的方式

以输入 96 日 Close 标准差为局部尺度，行情修正限制在 0.5 倍局部尺度内，每个辅助分支限制在 0.1 倍内。行情价格相对最后值居中；量能使用窗口内中心化，训练损失也按窗口尺度归一化。官方固定 Close 尺度仍用于报告指标，局部标准差设 1e-4 下限。

初步时间验证仍出现回退后，另登记六个价格反射补充对照。它们共享原模型权重，消除无条件漂移，其他训练条件保持匹配。此约束并不假定真实市场完全对称；未通过门槛时记录为负结果。

2 行情阶段的优化结果

阶段	配置对照	基线开发 MAE	改动开发 MAE	跨时间门槛
E1	E1_MAE → E1_Huber	0.217307	0.217307	未通过
E2	E2_GRU64 → E2_GRU16	0.214861	0.214937	未通过
E3	E3_drop01 → E3_drop03	0.214271	0.214327	未通过
E4	E4_full → E4_small	0.217307	0.217307	通过
E5	E5_layers2 → E5_layers1	0.217307	0.217307	未通过
E6	E6_raw → E6_stationary	0.217307	0.217307	未通过

E1 比较 MAE 和 Huber；E2 缩小 GRU 隐藏层；E3 提高通道 dropout；E4 整体缩小 PatchTST 容量；E5 减少 iTransformer 层数；E6 比较窗口归一化后的原始和平稳化表示。E4 是容量策略的整体比较，不把效果归因于某一个超参数。

消除无条件漂移的补充对照

补充配置	开发 MAE	相对匹配对照的门槛
S_E1_Huber	0.217307	未通过
S_E2_GRU16	0.217307	未通过
S_E3_drop03	0.217307	未通过
S_E4_small	0.217307	未通过
S_E5_layers1	0.217307	未通过
S_E6_stationary	0.217307	未通过

按预登记规则选中的行情骨干为 E3_drop01，seed42 行情资格通过。跨时间结论来自全部三组验证，不等同于每个阶段都获得正收益；epoch0 表示该范围未接受训练后的修正。

3 多模态阶段的优化结果

阶段	配置对照	基线开发 MAE	改动开发 MAE	验收
E7	E7_daily → E7_pooled	0.214271	0.214271	未通过
E8	E8_values → E8_ratios	0.214271	0.214271	未通过
E9	E9_dropout01 → E9_dropout05	0.214271	0.214271	未通过
E10	E10_modes13 → E10_modes3	0.214271	0.214271	未通过

E7 将 96 日展开的新闻输出头改为三个固定 32 日池化段，并重训只有篇数与掩码的对照。E8 比较财报数值、财务比率以及匹配掩码年龄。E9 比较 0.1 和 0.5 的模态 dropout。E10 将新闻与行情的交叉频谱模式从 13 降为 3，同时比较简单新闻分支。

内容和结构信息的区别

新闻选定分支为 E7_daily。开发集内容置零的 MAE 增量为+0.00000000。该诊断须结合重训覆盖或掩码对照，不能单独证明内容有效。

财报选定分支为 E8_values。开发集内容置零的 MAE 增量为+0.00000000。该诊断须结合重训覆盖或掩码对照，不能单独证明内容有效。

最终固定多模态配置为 E9_dropout01。按 seed42 跨时间、匹配单模态与内容门槛，整体验收未通过。即使完成导出与推理校验，未通过研究门槛也只能作为实验候选保留。

最终权重审查确认，三个种子的新闻和财报输出头均为 0，两个固定候选的预测完全一致。这套多模态配置尚未形成三模态有效依赖，仅作实验归档。

财报固定 180 日延迟，另做 270 日压力检查；历史版本仍有限。旧比率缓存在滚动 A 验证范围有 72 个字段发生不可逆截断，该比率实验仅作近似诊断，详见 AUDIT_LIMITATIONS.json。

4 三种子复验与最终测试

种子	行情开发 MAE	行情开发 MSE	多模态预测
42	0.214271	0.130360	与行情完全相同
43	0.214591	0.130443	与行情完全相同
44	0.214968	0.130491	与行情完全相同

表中是各次训练结果。最终预测固定使用 42、43、44 等权平均，先平均预测再计算误差；没有挑选分数最好的种子，也没有根据留出分数调整成员或权重。最终固定模型哈希写入 TEST_FREEZE.json 后才执行测试。

预测步长	行情留出 MAE	行情留出 MSE	E0 留出 MAE	E0 留出 MSE
1	0.116123	0.034538	0.115905	0.034499
6	0.309248	0.231551	0.306501	0.233465
12	0.359571	0.287600	0.350562	0.284610
24	0.492853	0.639363	0.482318	0.625727

交付与评分校验

两个候选均导出独立 model.py 与 model.pt，默认 build_model()严格加载。全开发预测与三个原模型平均一致；每个候选分别用 48 个原始开发样本去除 y 后核对预处理与推理，并通过 CPU/GPU 对齐和辅助模态全缺失检查。

最终内部留出每个固定候选仅评估一次，全部输出有限。重新计算 E0 与历史结果一致；用 PyTorch 对保存预测和原始标签独立复算指标，与 NumPy 差异小于 1e-12。测试后未再训练、调系数或改选种子。

5 当前决定与后续优先级

本轮提分目标未达成，两套导出文件均按实验产物保留。最终测试未证明新方案优于基线，多模态输出头归零也不满足有效三模态依赖。当前证据不支持把新包当作已通过验收的正式替代方案。

研究效果和课程交付需要同时审查。纯行情候选用于判断价格预测能力；课程原 README 还要求 forward 使用行情、新闻和财报三种模态。多模态代码能运行并不代表数值内容已经有益，是否满足有效依赖及内容增量须结合前述诊断。

第一优先级是保留未揭示的时间段：当前内部留出已反复可见，今后只用于描述，不继续围绕它搜索。若继续研究，应先固定新时间范围、训练截止点、标准化规则、基线和验收阈值，再统一比较。

第二优先级是按失败环节优化：行情侧审查局部尺度和各市场阶段的误差；新闻侧保留小容量与覆盖对照；财报侧补真实公告日及历史版本，并从原始记录生成不经过旧截断的比率。每次只扩展有明确证据的分支。

第三优先级是展示与提交整理：报告全部正负结果、固定平均方式、跨时间门槛以及测试边界。未通过验收的配置不写成稳定提升；纯行情模型的成绩不能替代三模态任务要求。

资源和复现入口

本轮实际训练与最终评估在 243 完成，主要复用 GPU 2、7、4，各卡一个本项目训练进程，独立 CUDA 依赖和约 6GiB 显存预算。236 保留上一轮独立推理验证环境，230 未用于本轮训练。

代码与预登记文件位于 experiments/temporal_robust_round2。结果位于其 results 子目录。PLAN.json 与 FOLLOWUP_PLAN.json 记录两步方案；market_selection.json、modal_selection.json 和 FINAL_SELECTION.json 记录阶段决策；TEST_FREEZE.json 和 final_holdout/summary.json 记录冻结证据及最终评估。

candidates/market 与 candidates/multimodal 包含独立模型；market_candidate.zip 及 multimodal_candidate.zip 均仅包含 model.py 和 model.pt。全部训练的 protocol.json、history.json、result.json 和最佳权重均保留，预测与日志保留用于复核。