实验路线与结果总报告

2026 年 11 月 2 日 历史基线与两批 GPU 优化汇总

截至目前，历史最佳内部留出研究成绩属于 E6 平稳化 DLinear：MAE 为 0.35034519，MSE 为 0.32020074。最后一轮预先冻结的 GRU 模型成绩为 0.36252380 和 0.33565344，两者属于不同实验记录，不能互换。

本报告整合既有基础研究、第一批 40 次 GPU 训练和第二批 108 次 GPU 训练。新增训练共 148 次；此前历史 CPU 实验不重复计入。今天只汇总并复算已保存的预测，未新增训练或模型推理。

应使用的成绩名称	模型与平均方式	内部留出 MAE	内部留出 MSE
历史最佳研究成绩	E6 DLinear 三种子预测平均	0.35034519	0.32020074
第一批 GPU 最终组合	B2 三成员乘三种子	0.36296970	0.33916921
最后一轮冻结模型	小型 GRU 三种子预测平均	0.36252380	0.33565344
官方最终成绩	官方隐藏测试	尚未产生	尚未产生

本次确定的分数口径

汇报“目前最好成绩”时，使用 E6 的 0.35034519 与 0.32020074，并注明它是历史已知内部留出结果。汇报“最后一轮最终模型”时，使用 GRU 的 0.36252380 与 0.33565344，明确该轮没有超过 E0 基线。

课程正式成绩仍未知：目前没有官方隐藏测试结果，也没有可据此换算为百分制总分的已确认评分公式。MAE 和 MSE 分别报告，不自行相加或转换成课程分数。

新一轮多模态配置的新闻与财报输出头最终均为 0，实际预测等同于行情 GRU。它没有形成有效三模态依赖。历史最佳 E6 也是纯行情模型，不能直接等同于通过课程三模态要求的正式提交。

1 任务数据与整体实验路线

任务使用过去 96 个交易日的行情、逐篇新闻向量和财报，预测未来 24 日标准化 Close。主指标为 MAE、MSE，24 个预测位置等权。训练样本 587,587 条；开发样本 42,930 条；隔离边界 18,630 条；内部留出 15,390 条。

阶段	模型或输入	需要回答的问题
E0	最后值基线	完全不训练能达到什么水平
E1	DLinear	线性时序残差能否提分
E2	单变量 GRU	非线性记忆是否优于线性
E3	多变量 GRU	其他行情字段是否提供增量
E4	PatchTST	局部时间片与注意力是否有效
E5	iTransformer	变量间注意力是否有效
E6	行情特征表示对照	原始与平稳化输入如何影响预测
E7	行情加新闻	语义是否超过篇数和覆盖信息
E8	行情加财报	数值是否超过掩码与报告年龄
E9	行情加新闻加财报	联合融合能否超过匹配单模态
E10	轻量频域融合	频谱结构能否超过简单新闻分支

PatchTST 和 iTransformer 均属于 Transformer 类模型。本轮实际比较了 DLinear、GRU 和这两类 Transformer；最终统一测试的第二批候选使用 GRU。E6 本身是特征表示实验编号，历史实现采用多变量 DLinear，并不是另一种 Transformer。

内部留出取公共 val 中最晚的预测起始日期，开发目标须全部早于留出开始。留出预测起始日为 2024 年 1 月 24 日至 2 月 27 日，共 810 只股票、19 个起始日，目标最晚到 3 月 29 日。开发目标最晚到 1 月 23 日。

该留出在历史研究中已被揭晓。其后结果用于如实记录跨时段表现，不能重新称为独立新盲测。官方隐藏测试文件没有提供。

2 既有研究与统一历史成绩

以下使用同一标准化 Close 尺度和原始时间切分。除 E0 外，表中为预定三种子的固定预测平均；增强 E1 可等价合并线性权重。先平均预测再算误差，区别于先算各次分数再平均。

模型	开发 MAE	开发 MSE	留出 MAE	留出 MSE
最后值基线	0.217307	0.131206	0.354286	0.330340
历史增强 DLinear	0.216052	0.130342	0.351294	0.324072
历史平稳化 DLinear	0.218733	0.132215	0.350345	0.320201
历史 DLinear 加新闻	0.217032	0.131258	0.358696	0.328664
历史 DLinear 加财报	0.218716	0.132207	0.350379	0.320236
历史新闻财报融合	0.217980	0.131718	0.352401	0.322431
历史频域融合	0.218591	0.132141	0.350691	0.320582
历史优化 PatchTST	0.215004	0.129781	0.353688	0.328020

历史路线的结论

E1 完成中心化、正则化、残差收缩和三种子复验。E6 扩展为七变量并比较平稳化表示，在这段留出上取得表中最低的 MAE 与 MSE；相对 E0 分别降低约 1.11%和 3.07%。这是描述性的历史最好结果，不据此事后挑选某个种子。

优化 PatchTST 在开发集优于增强 E1，但留出排序没有延续。E6 开发集反而弱于增强 E1 和 PatchTST。开发和留出排名反转，是后续加强时间验证的直接原因。

历史新闻、财报、联合和频域模型都未在留出上超过 E6。旧模态消融显示新闻语义或财报数值的响应很弱，因此不能把极小收益归因于内容有效。后续 F1/F2、M1/M2、S1/S2 正则化修复恢复了部分编码响应，但开发最佳检查点仍常回退 epoch0，未形成可靠升级。

历史 E8 为 0.35037913 与 0.32023650，接近但未超过 E6。不能因为某次“关闭新闻”消融或某个单种子更低，就将其改称最终新模型；这些结果不是独立重训的预定比较。

3 第一批 GPU 分阶段优化

第一批包含 23 个初始配置、9 个针对性后续配置和 8 次种子复验，共 40 次训练。使用完整官方训练集，主要按开发 MAE 下降至少 0.1%、MSE 不升、早晚开发段稳定及模态内容对照决定是否采用。训练在 243 完成，236 完成独立推理验证。

阶段	验证内容与实际结果
E1	提高 MSE 权重并测试固定残差收缩；最优回到 epoch0，未超过 E0。
E2	最后隐藏状态改平均池化；开发 MAE 由 0.213691 升至 0.215064，保留最后状态。
E3	非 Close 通道 dropout 为 0.1；MAE 由 0.216061 降至 0.214825，MSE 由 0.136561 降至 0.134980。单种子局部通过。
E4	修复历史训练与推理 alpha 规则后缩小前馈层；MAE 0.214783 降至 0.214705，改善仅 0.036%，MSE 略升，未采用。
E5	iTransformer 两层减一层；两版最优均回到 epoch0。
E6	原始与平稳化七变量、固定残差收缩；本批最优均回到 epoch0。
E7	新闻向量归一化及最近 20 日窗口；未稳定超过重训覆盖对照。
E8	财报线性头和财务比率；比率 MAE 0.214527，掩码对照 0.214324，数值增量未通过。
E9	单模态预训练再联合训练；开发 MAE 0.213254，但时段和内容门槛未通过，未因最低总分直接采用。
E10	频率模式 13 减 7；最优回到 epoch0，未超过简单新闻分支。

最后预先固定 B2：完整新闻、新闻覆盖、财报结构三个成员，乘以 42、43、44 三个种子等权预测平均。开发 MAE/MSE 为 0.21370155/0.12904843；实际内部留出为 0.36296970/0.33916921，未泛化。

B2 的财报输入是掩码、可用性和报告年龄，未证明财报数值有效；其三个 E6 父模型均选零残差 epoch0，行情主干实际是最后价格锚点。不能把这批开发收益归因于 DLinear 学到了新的历史动态。

4 第二批 GPU 时间稳定性优化

第二批先训练 22 个阶段配置，再根据早期回退现象登记 6 个价格反射补充配置。28 个配置分别训练两个历史时间切分与原开发范围，共 84 次；固定四个必要组件补 seed43、44，各三个范围，共 24 次。合计 108 次训练、310 个 epoch。

验证范围	训练样本	验证样本	目标日期规则
rolling_A	440,221	29,152	训练目标结束早于 2023 年 1 月 3 日；验证起始日 1 月 3 日至 2 月 28 日。
rolling_B	535,747	33,210	训练目标结束早于 2023 年 7 月 3 日；验证起始日 7 月 3 日至 8 月 31 日。
development	587,587	42,930	全部官方训练样本与原开发切分。

使用输入窗口局部尺度和有界残差，每个范围按最差日期块相对 E0 的 MAE 与 MSE 选轮；再以跨范围改进、每段退化上限决定采用。日期块可能有目标重叠，不能视为独立重复。六个反射补充模型用于消除无条件漂移，没有通过完整匹配门槛。

阶段	本批改动	跨时间匹配验收
E1	MAE 与 Huber 损失	未通过
E2	GRU 隐藏层 64 减 16	未通过
E3	七变量 GRU16 的 dropout 0.1 改 0.3	未通过，保留 0.1
E4	PatchTST 整体缩小容量	跨范围通过，开发仍为 epoch0
E5	iTransformer 两层减一层	未通过
E6	窗口归一化原始与平稳化输入	未通过

综合时间验证选中 E3_drop01：七变量 GRU16、非 Close 通道 dropout 0.1。随后 E7 比较每日展开与三段新闻池化，E8 比较财报数值、比率和掩码，E9 比较模态 dropout 0.1/0.5，E10 比较 13/3 个交叉频谱模式；均未通过完整模态验收。

所有阶段和三种子复验结束后，才导出并冻结行情与多模态两套候选，再统一测试一次。最终两套预测完全一致，MAE 为 0.36252380、MSE 为 0.33565344，仍差于 E0。测试后没有继续训练或调整成员。

5 最终模型分数与交付状态

固定实验对象	开发 MAE	开发 MSE	留出 MAE	留出 MSE
历史平稳化 DLinear	0.218733	0.132215	0.350345	0.320201
第一批 GPU 固定 B2 组合	0.213702	0.129048	0.362970	0.339169
最新小型 GRU	0.214591	0.130413	0.362524	0.335653
最新多模态实验配置	0.214591	0.130413	0.362524	0.335653

最后一轮三种子复验

种子	GRU 开发 MAE	GRU 开发 MSE	多模态实际预测
42	0.214271	0.130360	与对应行情模型相同
43	0.214591	0.130443	与对应行情模型相同
44	0.214968	0.130491	与对应行情模型相同

最后一轮开发成绩 0.21459135/0.13041289 是先平均三个种子的预测再评分，不是表中三个分数的算术平均。最终固定 GRU 在内部留出相对 E0 的 MAE 和 MSE 分别恶化约 2.33%和 1.61%。

最终多模态权重审查发现，三个种子的新闻与财报输出头全部为 0，因此任何有效输入下均退回行情预测。它没有通过有效三模态依赖；两个包只能作为实验产物归档，不能写成已验证提分的正式替代方案。

代码能够运行与研究有效性分别验收

两套最新模型均完成独立 model.py 与 model.pt 导出、无参数 build_model 重载、48 个去除 y 的原始开发样本核对、CPU/GPU 一致性和缺失模态有限输出检查。原始样本预测最大差异约 2.38e-7。技术接口通过，不代表模态内容有效或正式成绩合格。

根目录 model.py 保留原模板，实验导出包分别存放。历史 E6 纯行情成绩、第一批 B2 输入结构信息的成绩，以及最新 GRU 成绩，都须保留各自模型身份。尚未得到兼具已验证提分和有效三模态依赖的新提交方案。

6 分数确认与复现证据

本次直接读取原始 val.npz 标签、固定样本索引和已保存预测，独立以 float64 复算 MAE 及 MSE。E0、增强 E1、历史 E6/E7、B2 和最新两套候选共 7 组均与原记录一致，绝对差不超过 1e-12；没有重新运行模型推理。

同时核对历史 E6 三个检查点、B2 导出文件以及最新两套导出文件的 SHA256。汇总没有改动模型、预测、候选成员或选模结果。精确分数和校验哈希写入 scores.json，148 次运行明细写入 runs.json。

证据文件

experiments/experiment_summary_20261102/scores.json

统一成绩表、分数口径、保存预测复算及模型哈希。

experiments/experiment_summary_20261102/runs.json

两批新增 148 次训练的配置、种子、范围、最佳轮数和分数。

experiments/e1_dlinear/e6_plus/results/holdout/summary.json

历史 E6 及匹配 E7、E1、E0 的固定留出记录。

experiments/gpu_stage_optimization/ensemble/final_summary.json

第一批 B2 的开发结果、模型组成和输入诊断。

experiments/gpu_stage_optimization/holdout_20261101/summary.json

第一批 B2 的实际内部留出分数。

experiments/temporal_robust_round2/results/FINAL_SELECTION.json

第二批测试前固定的候选与研究验收状态。

experiments/temporal_robust_round2/results/TEST_FREEZE.json

最终候选哈希、等权方式和开发重载校验。

experiments/temporal_robust_round2/results/final_holdout/summary.json

最后一轮统一测试的精确分数。

experiments/temporal_robust_round2/results/MODEL_AUDIT.json

最新新闻与财报输出头归零的权重审计。

财报缺少真实历史版本；旧比率缓存存在不可逆截断，滚动 A 验证涉及 72 个字段，相关比率滚动实验仅为近似诊断。已知内部留出已被反复观察，今后不能以此继续搜索后再声称独立泛化。